Loop LLM 项目方案

固定深度 RLTT 裁剪目标与循环内有向蒸馏

版本 1（确认稿） | 2026 年 10 月 18 日 | 方法设计，尚无实验结论

1 目标、模型、采样与奖励

目标与结构。固定 $R \geq 2$，提高末轮答案质量；比较两种梯度路径与多 GPU 批内并行：

$$\max_{\Phi} J_R(\Phi) = \mathbb{E}_{x,\, y\sim\pi_{\Phi}^{(R)}(\cdot|x)}[\mathcal{R}(x,y)], \qquad \Phi = \{\phi_1, \ldots, \phi_R\}. \tag{1}$$

共享主干 W_0、输出模块 G 均冻结；各轮独立 LoRA。每个选定线性映射满足

$$W_r = W_0 + \frac{\alpha_{\mathrm{L}}}{d_{\mathrm{L}}} U_r V_r, \qquad \phi_r = (U_r, V_r), \qquad U_r^{(0)} = 0, \quad V_r^{(0)} \text{ 各轮独立随机初始化.} \tag{2}$$

随机初始化分布与尺度待定；A/B 复制同一组初始参数。G 含原有最终归一化与词表投影，冻结其参数不阻断对隐藏输入的梯度。令 c_r 为本轮其他条件：

$$\begin{aligned} s_{it} &= (x_i, y_{i,<t}), & h_{it}^{(r)} &= F_{W_0,\phi_r}(h_{it}^{(r-1)}; s_{it}, c_r), \\ \mathrm{Read}_T(h) &= \mathrm{softmax}(G(h)/T), & q_{itr} &= \mathrm{Read}_T(h_{it}^{(r)}), \qquad T > 0. \end{aligned} \tag{3}$$

h 简写完整因果隐藏输入；位置、掩码与注意力上下文须一致。中间轮仅读出概率，主链传递隐藏状态；训练读出严格对应预测 y_{it} 的位置，不读取未来 token。

采样与掩码。每题采样 $M \geq 2$ 条回答，实际 token 仅来自旧策略末轮：

$$y_{it} \sim p_{itR}(\cdot \mid s_{it}), \qquad m_{it} = \begin{cases} 1, & \text{实际生成的回答 token，含真实 EOS,} \\ 0, & \text{prompt 或 padding.} \end{cases} \tag{4}$$

旧学生、当前学生、教师及采样使用相同温度定义与全词表 softmax；不采用 top-p/top-k 采样截断。Top4 仅用于蒸馏。所有分支的主干与 LoRA Dropout 均关闭；截断回答不补 EOS。

结果奖励。生成与判分正常运行时，采用二值奖励：

$$u_i = \mathbf{1}[\text{正常结束} \ \wedge \ \text{最终答案可解析} \ \wedge \ \text{答案正确}]. \tag{5}$$

错误、正常结束但不可解析、长度截断未完成均记 0 并保留；截断文本即使含正确答案也记 0。生成或判分报错、超时等技术故障：暂停当前批次并保留信息，不自动重试、丢弃或改记 0。

优势与全批归约。同题组 $\mathcal{I}_x$ 含 M 条回答；一个完整 rollout 批次含 N 条回答：

$$\mu_x = \frac{1}{M}\sum_{j\in\mathcal{I}_x} u_j, \qquad s_x = \sqrt{\frac{1}{M}\sum_{j\in\mathcal{I}_x}(u_j - \mu_x)^2}, \qquad A_i = \frac{u_i - \mu_x}{s_x + \varepsilon_A}, \quad \varepsilon_A > 0. \tag{6}$$

$$A_{it} = A_i, \qquad T_i = \sum_t m_{it}, \qquad \langle z_{it}\rangle_{\mathcal{D}} = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{T_i}\sum_t m_{it} z_{it}. \tag{7}$$

优势向 token 与循环广播；不增加逐 token/逐轮奖励模型。$s_x = 0 \Rightarrow A_i = 0$，该组仍保留在平均分母中，不过滤、不补采样。两损失分支均采用上述回答等权归约。

2 固定教师与两分支裁剪目标

快照与同输入教师。批次 b 开始时冻结 $\bar{\Phi}_b = \Phi_{b,0}$，同时作为采样旧策略与教师；该批复用 $K > 1$ 次。省略 (b, i, t)，定义

$$\begin{aligned} \bar{h}^{(r)} &= F_{W_0,\bar{\phi}_r}(\bar{h}^{(r-1)}; s, c_r), & p_r &= \mathrm{sg}[\mathrm{Read}_T(\bar{h}^{(r)})], \\ \tilde{h}^{(r)} &= F_{W_0,\bar{\phi}_{r+1}}(\mathrm{sg}[\bar{h}^{(r-1)}]; s, c_r), & \tilde{p}_r &= \mathrm{sg}[\mathrm{Read}_T(\tilde{h}^{(r)})], \quad r < R. \end{aligned} \tag{8}$$

教师只将第 r 轮 LoRA 替换为下一轮 LoRA；其余条件仍取 c_r。教师使用旧学生隐藏输入，独立重算所需 KV，不复用正常第 $r+1$ 轮旧 KV。它不同于主链下一状态 $F_{r+1}(\bar{h}^{(r)})$。

固定窗口。旧概率、候选、教师分布及优势在批内只计算一次；当前学生每次更新重新前向：

$$\mathcal{T}_b = \mathrm{sg}\{p, \tilde{p}, S, w, d, A, \hat{b}\}, \qquad \mathcal{T}_b^{(k)} = \mathcal{T}_b^{(0)}, \quad k = 0, \ldots, K-1. \tag{9}$$

更新后当前输入 $h_{b,k}^{(r-1)}$ 可偏离 $\bar{h}_b^{(r-1)}$，不据此刷新教师；下一批重新建立快照与目标。q^{RL}、q^{OPD} 前向数值相同，梯度路径按第 3 节区分。

裁剪算子。对分支 $a \in \{\mathrm{RL}, \mathrm{OPD}\}$，分别使用自己的裁剪阈值：

$$\rho_{itr}^a(v) = \frac{q_{itr}^a(v)}{p_{itr}(v)}, \qquad \mathcal{C}_a(\rho, z) = -\min\{\rho z,\ \mathrm{clip}(\rho, 1-\epsilon_a^-, 1+\epsilon_a^+)z\}. \tag{10}$$

$$\boxed{\omega_r = \frac{1}{R}, \qquad \mathcal{L}_{\mathrm{RL}} = \left\langle \frac{1}{R}\sum_{r=1}^{R} \mathcal{C}_{\mathrm{RL}}\big(\rho_{itr}^{\mathrm{RL}}(y_{it}), \mathrm{sg}[A_i]\big) \right\rangle_{\mathcal{D}}.} \tag{11}$$

先逐 token、逐轮裁剪，再归约。该式是对 RLTT 原目标的扩展；原论文式 (4) 及核心实现不含此概率比率裁剪 [1, 2]。实际 token 来自末轮，中间比率不是同分布动作采样的标准重要性校正。

Top4 蒸馏信号。对 $r < R$，沿用 OpenClaw-RL 的候选加权构造 [3, 4]：

$$S_{itr} = \mathrm{Top4}(p_{itr}), \qquad w_{itrv} = \mathrm{sg}\left[\frac{p_{itr}(v)}{\sum_{u\in S_{itr}} p_{itr}(u)}\right], \qquad d_{itrv} = \mathrm{sg}\left[\mathrm{clip}\left(\log\frac{\tilde{p}_{itr}(v)}{p_{itr}(v)}, -c, c\right)\right]. \tag{12}$$

$$\boxed{\gamma_\tau(A) = 2\sigma(A/\tau) - 1 = \tanh\left(\frac{A}{2\tau}\right), \qquad \hat{b}_{itrv} = \mathrm{sg}[\gamma_\tau(A_i) w_{itrv} d_{itrv}], \quad \tau > 0.} \tag{13}$$

$$\ell_{itr}^{\mathrm{OPD}} = \sum_{v\in S_{itr}} \mathcal{C}_{\mathrm{OPD}}\big(\rho_{itr}^{\mathrm{OPD}}(v), \hat{b}_{itrv}\big), \qquad \boxed{\mathcal{L}_{\mathrm{OPD}} = \left\langle \frac{1}{R-1}\sum_{r=1}^{R-1} \ell_{itr}^{\mathrm{OPD}} \right\rangle_{\mathcal{D}}.} \tag{14}$$

最后一轮无 OPD。候选求和，不再除以 4；只有 w 在 Top4 内归一化，所有概率仍按全词表归一化。EOS 所在预测位置照常处理，不强制 EOS 或实际 token 进入 Top4。

总目标。 γ 作用于裁剪前的蒸馏优势；负值时不可移至裁剪后。两分支分别裁剪后合并：

$$\boxed{\mathcal{L} = \lambda_{\mathrm{RL}}\mathcal{L}_{\mathrm{RL}} + \lambda_{\mathrm{OPD}}\mathcal{L}_{\mathrm{OPD}}.} \tag{15}$$

不将两类奖励先相加再做组内标准化；损失权重与阈值数值待定。参考 KL、熵奖励、权重衰减均不启用，梯度范数裁剪关闭；保留本页的 PPO 裁剪及教师差分裁剪 c。

3 梯度路由、批内更新与停止规则

局部路径。 sg 为停止梯度。当前学生的本轮局部读出定义为

$$h_{\mathrm{loc}}^{(r)} = F_{W_0,\phi_r}(\mathrm{sg}[h^{(r-1)}]; s, c_r), \qquad q_{\mathrm{loc}}^{(r)} = \mathrm{Read}_T(h_{\mathrm{loc}}^{(r)}). \tag{16}$$

局部输入取当前学生主链的数值，不以旧快照隐藏状态替代。轮内因果计算仍保留；仅截断跨轮输入的梯度。G 可传递输入梯度，旧学生与教师均不接收梯度。

A/B 唯一预定差异。令 $\mathcal{L}_r^{\mathrm{RL}}$、$\mathcal{L}_r^{\mathrm{OPD}}$ 已含各自的 token、回答及轮次归约权重，$\mathcal{L}_R^{\mathrm{OPD}} = 0$：

$$\boxed{g_j^A = \lambda_{\mathrm{RL}} \sum_{r=j}^{R} \nabla_{\phi_j} \mathcal{L}_r^{\mathrm{RL}} + \lambda_{\mathrm{OPD}} \partial_{\phi_j}^{\mathrm{loc}} \mathcal{L}_j^{\mathrm{OPD}}.} \tag{17}$$

$$\boxed{g_j^B = \lambda_{\mathrm{RL}} \partial_{\phi_j}^{\mathrm{loc}} \mathcal{L}_j^{\mathrm{RL}} + \lambda_{\mathrm{OPD}} \partial_{\phi_j}^{\mathrm{loc}} \mathcal{L}_j^{\mathrm{OPD}}.} \tag{18}$$

项目	A：主版本	B：对照版本
第 r 轮 RLTT 更新范围	$\phi_1, \ldots, \phi_r$	ϕ_r
第 r 轮 OPD 更新范围	仅 ϕ_r	仅 ϕ_r
当前主链	RLTT 保留跨轮计算图	各轮边界停止梯度
OPD 路由	独立限定本轮梯度	与本轮局部 RLTT 合并
共同更新边界	全批、两分支梯度汇集后	同左

A 不得对两分支共用的未截断计算图直接执行总损失反向，使 OPD 泄漏至前轮。也不得整体截断 A 的 RLTT 主链。各分支梯度先相加，再执行一次优化器更新；分开执行两次优化器步不等价。

整批复用。对每个非全零优势批次，以完整 $\mathcal{D}_b$ 计算每一步梯度：

$$(\Phi_{b,k+1}, \mathcal{S}_{b,k+1}) = \mathrm{OptStep}(\Phi_{b,k}, \mathcal{S}_{b,k}, g_{\mathcal{D}_b}^{A/B}(\Phi_{b,k}; \mathcal{T}_b)), \quad k = 0, \ldots, K-1. \tag{19}$$

$\mathcal{S}$ 为优化器状态；优化器类型、学习率与 K 数值待定。显存不足可拆微批次，全部累积完才更新；各 GPU 与微批次的归约须保持全批回答等权。每步重新计算当前学生；前向或教师任务仍读取参数时不得原位更新。

全零优势批次。判据覆盖全部 GPU 与全部微批次，不以总损失数值为零代替：

$$[\forall i \in \mathcal{D}_b,\ A_i = 0] \Longrightarrow \begin{cases} \text{跳过该批全部优化器步及对应的按更新步数运行的学习率调度,} \\ \Phi,\ \mathcal{S}_{\mathrm{opt}},\ \mathcal{S}_{\mathrm{lr}},\ n_{\mathrm{update}} \text{ 保持不变,} \\ \text{保留样本、组及 rollout 消耗记录，不补采样.} \end{cases} \tag{20}$$

部分组优势为零时仍保留在全批平均分母中。$L = 0$ 可由正负项抵消产生，不蕴含 $\nabla L = 0$。

停止与选模。预先固定 rollout 批次数 $B_{\max}$、问题序列和每题采样数；零优势批次计入预算：

$$b = 1, \ldots, B_{\max}, \qquad \Phi_{\mathrm{report}} = \Phi_{\mathrm{end}}, \qquad n_{\mathrm{update}}^A \text{ 与 } n_{\mathrm{update}}^B \text{ 可不同.} \tag{21}$$

不为补足更新次数延长训练。中间验证仅观察，不提前停止、不挑选最佳检查点；测试集不参与选模或调参。A/B 初始化、数据、奖励、损失设置、预算与计划一致，优化器状态独立；各自生成的轨迹可自然分化。

4 批内执行、多 GPU 并行与启动行为

逻辑流程。目标准备可与已就绪的旧学生主链重叠；最终优势须等待组内回答与评分完成：

阶段	计算	版本或依赖
1	冻结 $\bar{\Phi}_b$，末轮策略分组采样	学生旧快照同时作为教师快照
2	参考前向与同输入教师分支	一次性生成 $p, \tilde{p}, S, w, d$
3	判分、组内标准化及门控	得到 $A_i, \gamma_\tau(A_i), \hat{b}$；技术故障暂停
4	当前学生重算、两分支损失及梯度汇集	$\mathcal{T}_b$ 固定，按 A/B 路由，整批一次更新
5	重复阶段 4 共 K 次，再进入下一批	全零优势批次跳过更新；不超过固定预算

未知奖励时可先准备 $p, \tilde{p}, S, w, d$，但不可提前确定 $\hat{b}$ 的符号。完整回答已知的训练重算可在因果掩码下批量计算 token 位置；自回归 rollout 的下一 token 仍依赖已生成前缀。

已确认的三项并行。以下省略 (b, i, t) 及其余一致条件：

$$\begin{aligned}
&\text{P1 (A/B)}: \quad F_{\bar{\phi}_r}(\bar{h}^{(r-1)}; c_r) \;\parallel\; F_{\bar{\phi}_{r+1}}(\mathrm{sg}[\bar{h}^{(r-1)}]; c_r),\\
&\text{P2 (A/B)}: \quad G(h^{(r)}) \;\parallel\; F_{\phi_{r+1}}(h^{(r)}; c_{r+1}),\\
&\text{P3 (B)}: \quad \partial^{\mathrm{loc}}_{\phi_r}(\lambda_{\mathrm{RL}}\mathcal{L}^{\mathrm{RL}}_r + \lambda_{\mathrm{OPD}}\mathcal{L}^{\mathrm{OPD}}_r) \;\parallel\; F_{\phi_{r+1}}(\mathrm{sg}[h^{(r)}]; c_{r+1}).
\end{aligned} \tag{22}$$

P1 用于固定目标准备，不在批内每次更新后刷新教师。P3 要求本轮损失输入全部就绪，提前反向不等于提前更新。A 可提前算本轮 OPD 局部梯度，但 RLTT 跨轮反向仍依赖后续计算图。

设备与依赖。学生设备组负责主链、读出与反向；教师设备组运行冻结快照的无梯度前向。教师可在 Top4 索引就绪前计算，之后返回候选的全词表归一化概率。完整因果上下文传输与 KV 重算均计入成本；GPU 数量、互连与具体映射待定。

真正的主链第 $r+1$ 轮须等待 $h^{(r)}$。当前不采用跨批次 rollout 与训练重叠。并行目标是减少墙钟时间，不预设总计算量下降。

理想前向估算。若每轮块耗时 T_F，两个设备组资源充足，忽略读出、通信与反向：

$$T_{\mathrm{serial}} \simeq (2R-1)T_F, \qquad T_{\mathrm{parallel}} \simeq RT_F, \qquad S_{\mathrm{ideal}} \simeq 2 - \frac{1}{R}. \tag{23}$$

此式仅覆盖主链与教师分支的前向重叠；不代表端到端训练加速比。实测需包括目标准备、通信、读出、同步及反向。

复查结论：首批整段复用均无 OPD 信号。忽略浮点误差，由零增量初始化、相同输入与条件可得

$$U_r^{(0)} V_r^{(0)} = 0 \Longrightarrow \tilde{p}_{1,itr} = p_{1,itr} \Longrightarrow d_{1,itrv} = 0 \Longrightarrow \boxed{\nabla_\Phi \mathcal{L}^{(b=1,k)}_{\mathrm{OPD}} = 0, \quad k = 0, \ldots, K-1.} \tag{24}$$

首批目标始终固定，故不是仅第一个优化器步无蒸馏。首批只能由 RLTT 提供梯度；若全批优势也为零，则整批跳过更新。各轮产生差异且后续批次刷新目标后，才可能出现非零 OPD 信号。两分支从训练开始即纳入定义，不额外设置预热阶段。

5 研究边界、评价与未决配置

理论定位。当前定义构成可执行的训练代理目标，但不保证 J_R 单调提升。主要待验证假设为

$$\text{sign}(A_i) \not\Rightarrow \text{sign}(\text{第}r{+}1\text{ 轮教师对第}r\text{ 轮的因果收益}), \qquad q_r(y)\uparrow \not\Rightarrow\ q_R(y)\uparrow. \tag{25}$$

同输入教师分支未参与实际 rollout，下一轮 LoRA 不必更优；负向门控可能抑制有益修正。局部梯度隔离也不保证功能分工。Top4 截断目标不是全词表 KL 的精确值或一般无偏估计，负门控不等同于保证增大全词表 KL。

裁剪与来源差异。 PPO 裁剪不是硬性信赖域约束。在新旧策略相同且采用相同梯度路径时，未激活裁剪的 RL 分支梯度与原 RLTT 对应；B 的局部路由另作消融。RLTT 核心实现按全部有效 token 取平均，本项目已选择回答等权平均 [2]。OpenClaw-RL 源码另有

$$\log p - \log q \ \mapsto\ \text{clip}(\log p - \log q, -20, 20); \qquad \text{该额外限幅未纳入本项目。} \tag{26}$$

该限幅不同于 PPO 裁剪及教师差分裁剪 c，不可默认继承源码 [3]。实现须遵循已确认公式，不擅自增加限幅、正则化、筛样或重采样。

保留备选，不纳入主版本。

$$\gamma_{\tau,\eta}(A) = \begin{cases} \gamma_\tau(A), & A \geq 0, \\ \eta\,\gamma_\tau(A), & A < 0, \end{cases} \qquad 0 \leq \eta \leq 1. \tag{27}$$

主版本使用对称奇 sigmoid；弱化负向强度的方案仅留作后续候选。

最终评价。固定 R、相同解码预算与评估规则，在预先划定的测试集上报告训练结束模型：

$$\text{Acc}_R = \frac{1}{N_{\text{test}}} \sum_{j=1}^{N_{\text{test}}} \mathbf{1}[\text{Check}(x_j, \hat{y}_j) = 1]. \tag{28}$$

同时记录实际更新数、rollout 数、生成 token 数、训练墙钟时间、有效 token 吞吐及每卡峰值显存。相同 rollout 数不等于相同 token 数或计算量；数据集、判分器、评估解码与统计细则须在实验前固定。

仍待配置，不以默认值代替确认。

类别	待定内容
模型与数据	基础模型、LoRA 注入模块、$R, d_{\text{L}}, \alpha_{\text{L}}$、随机矩阵分布/尺度；数据划分、问题序列、答案解析与判分实现
训练数值	$\lambda_{\text{RL}}, \lambda_{\text{OPD}}, \tau, c, \epsilon^{\pm}_{\text{RL}}, \epsilon^{\pm}_{\text{OPD}}, \varepsilon_A, T$；$M$、长度预算、批量与微批量、$K, B_{\max}$
优化与系统	优化器、学习率与调度；GPU 型号/数量/互连、设备映射、精度及重算方式
评估与记录	评估解码参数、随机种子与重复次数、统计方式及中间验证频率；保存最终生效配置与版本

复查未发现已确认主流程之间的新冲突；尚未实现训练代码或验证研究效果。正式实验前补齐配置，并分别验证实现符合约定、运行正确与研究假设成立。

参考文献

[1] J. Williams, E. Tureci. Prioritize the Process, Not Just the Outcome. arXiv:2602.10520v3, 2026；式 (4)–(7)、第 4.1 节。

[2] RLTT：`rltt_algos.py`，`compute_rltt_policy_loss`。

[3] OpenClaw-RL：`hint_opd_loss.py`，Top-K OPD；核对日期：2026-10-18。

[4] OpenClaw-RL：`openclaw_topk_select_loss.py`，双分支组合。每轮 LoRA、同输入教师、符号门控与 A/B 路由为本项目组合设计。